Score de Dépendance SDS (le niveau ou la gravité de la dépendance à une drogue ou à une substance psychoactive chez une personne.)

RAPPORT D'ANALYSE EXPLORATOIRE ET DE TRAITEMENT DES DONNÉES De santé mentale

Direction de la Data & Analytics

Juillet 2026

Table des matières

Table des matières 2
1. Contexte et objectifs 3
1.1 Description du jeu de données 3
2. Structure et qualité des données 3
2.1 Nature des variables 4
2.2 Variable cible 5
2.3 Valeurs manquantes par variable 6
2.3 Anomalie détectée sur la variable catégorielle « Genre » 6
3. Nettoyage des données 7
3.1 Suppression des doublons 7
3.2 Correction des incohérences catégorielles 7
3.3 Traitement des valeurs aberrantes (méthode IQR) 7
3.4 Bilan du nettoyage 7
4.Analyse univariée des variables quantitatives 8
4. Analyse univariée Variables catégorielles 15
4.1 Type de drogue 15
4.2 Fréquence consommation de drogue 16
4.3 Soutien familial 17
4.4 Milieu résidence 17
4.5 Niveau scolaire 18
7. Analyse bivariée Variables numériques vs variable numérique 19
7.1 Age de première consommations vs le score de dépendance SDS 19
8. Analyse bivariée Variable catégorielle vs variable numérique 20
8.1 Score de dépendance vs fréquence de consommation 20
8.2 Type de drogue vs score de dépendance 21
9. Apports et limites de l'analyse exploratoire 22
Conclusion 22

1. Contexte et objectifs

Ce rapport présente l'analyse exploratoire et le traitement de la base de données, portant sur la consommation de drogue chez les jeunes dans un centre de santé mentale, avec pour objectif final l'étude de la variable score_qualite_vie.

L'objectif est de dresser un état des lieux fiable des données (inspection et nettoyage), puis d'en extraire les tendances clés à travers une analyse univariée (variable par variable) et bivariée (relations entre variables), afin d'orienter les décisions de la santé mentale.

L'objectif de ce projet n'est donc pas de prédire le type de drogue, mais de poser des bases méthodologiques solides et rigoureuses.

1.1 Description du jeu de données

Le jeu de données contient 600 observations et 19 variables :

- Variables catégorielles : sexe, niveau scolaire, milieu résidence, situation familiale, type_drogue_principale, type_drogue_principale, frequence_consommation, influence pairs, antecedents_familiaux_addiction, soutien familial
- Variables numériques : id jeune, âge, Age_premiere_consommation, duree_consommation_mois, score_dependance_SDS, score_estime_soi, score_qualite_vie, score_anxiete_HAM_A, heures_reseaux_sociaux_jour, revenu_familial_fcfa

Cette diversité de variables justifie une analyse exploratoire structurée et progressive

2. Structure et qualité des données

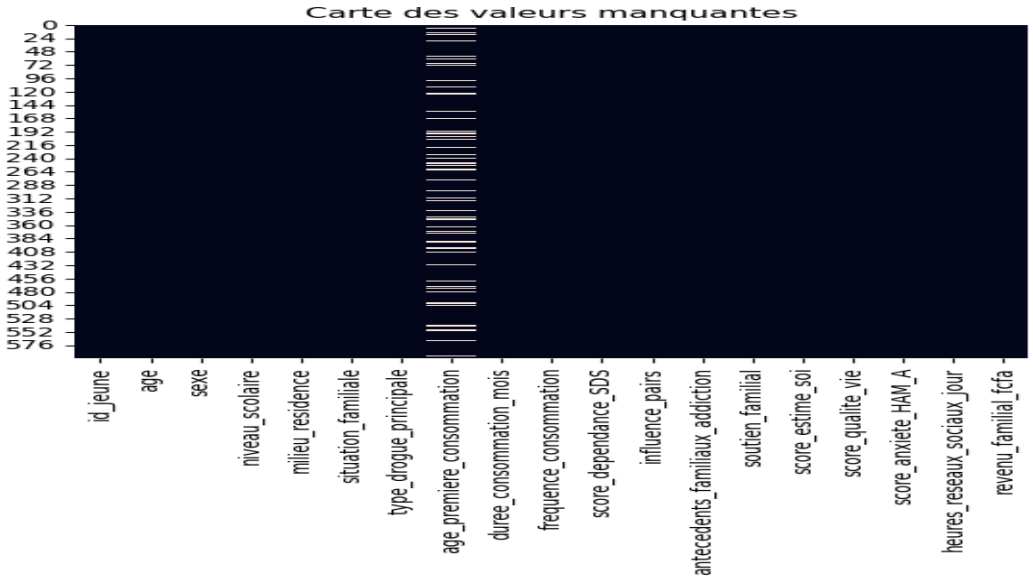
Avant toute modélisation prédictive ou analyse causale, il est indispensable de réaliser une analyse exploratoire approfondie, afin de :

- Comprendre la structure des données,
- Identifier la nature des variables,
- Détecter les déséquilibres, anomalies ou valeurs manquantes,
- Types de variables, doublons et cohérence des modalités catégorielles
- et choisir des méthodes statistiques adaptées.

600 Lignes (brut)	**19** Colonnes	**0** Doublons détectés	**80** Cellules manquantes

Une seule variable présente des **valeurs manquantes** : Age_premiere_consommation

, avec 80 valeurs manquantes, toutes les autres variables sont complètes.



Ce graphique montre le nombre de valeurs manquantes pour chaque variable du jeu de données. Une seule variable se distingue clairement : Age_premiere_consommation.

Interprétation

La présence de valeurs manquantes est localisée exclusivement sur la variable Age première consommation. Les autres variables sont complètes.

Lien avec la problématique :

Cela signifie que :

L'Age première consommation devra être traité avec précaution avant toute analyse approfondie ou modélisation liée du score de dépendance SDS.

2.1 Nature des variables

- Variables catégorielles : sexe, niveau scolaire, milieu résidence, situation familiale, type_drogue_principale, type_drogue_principale, frequence_consommation, influence pairs, antecedents_familiaux_addiction, soutien familial
- Variables numériques : id jeune, âge, Age_premiere_consommation, duree_consommation_mois, score_dependance_SDS, score_estime_soi, score_qualite_vie, score_anxiete_HAM_A, heures_reseaux_sociaux_jour, revenu_familial_fcfa

Cette distinction est essentielle car elle :

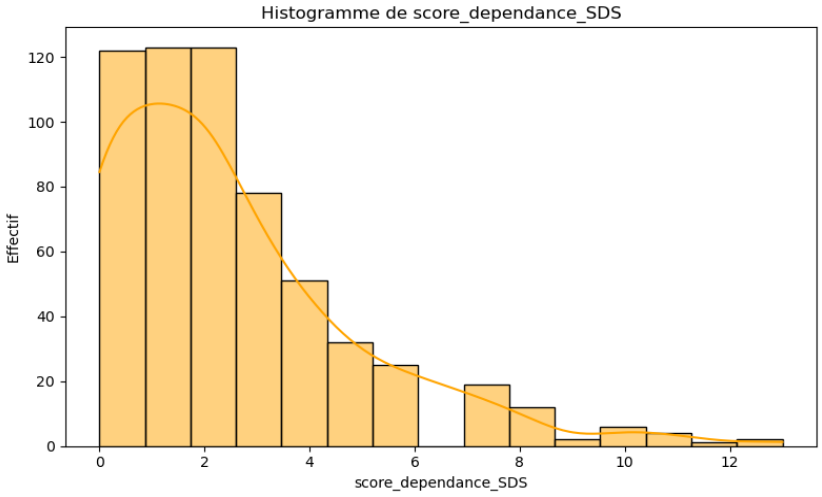
- Conditionne les tests statistiques utilisés,
- Empêche les erreurs méthodologiques,
- Guide le choix des visualisations.

Par exemple, les variables quantitatives ne suivent pas toutes une loi normale, ce qui exclut l'usage systématique de tests paramétriques

2.2 Variable cible

Statistique	Valeur
Moyenne	2.5100
Médiane	2.0000
Écart-type	2.4103
Minimum	0.0000
Maximum	13.0000
1er quartile (Q1)	1.0000
3e quartile (Q3)	4.0000
Asymétrie (skewness)	1.406
Aplatissement (kurtosis)	2.223

Le score_dependance_SDS est un score qui mesure à quel point une personne est dépendante d'une drogue ou d'une substance.



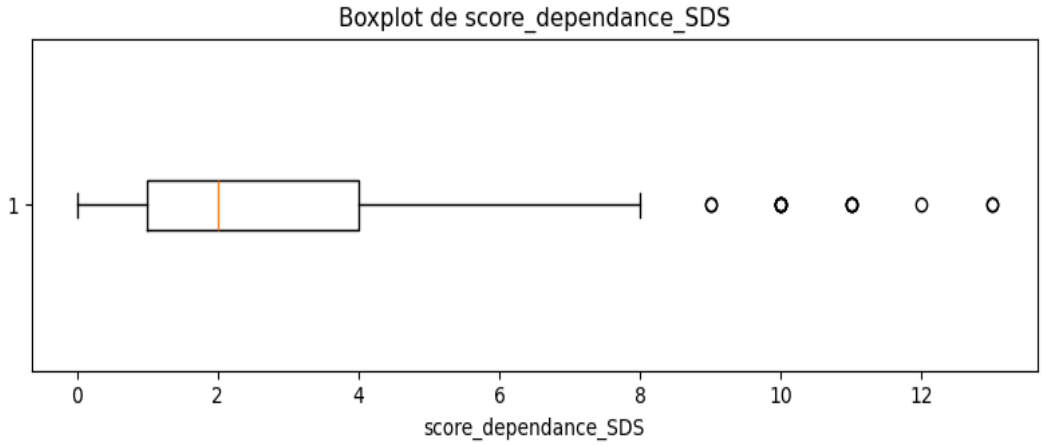
L'histogramme montre une forte concentration des données sur la gauche avec une longue queue étirée vers les valeurs élevées (asymétrie à droite ou *skewness* positive).

Les effectifs sont maximalement élevés (environ 122 patients par classe) et constants pour les scores compris entre 0 et 2,6.

Le coefficient d'aplatissement de kurtosis traduit un étalement important vers la droite en raison des valeurs extrêmes, bien que le sommet présente un plateau sur les premiers intervalles.

Interprétation

La grande majorité des patients présente un score de dépendance faible (faible dépendance SDS), avec une zone de forte fréquence située principalement entre 0 et 2,6. Seule une minorité de sujets atteint des scores de dépendance élevés (supérieurs à 6)



Le boxplot met en évidence plusieurs valeurs atypiques situées à droite, au-delà de la moustache supérieure (scores supérieurs à 8).

Cela indique qu'un sous-groupe minoritaire de patients présente des scores de dépendance nettement plus élevés que le reste du groupe.

2.3 Valeurs manquantes par variable

Variable	Nb. Valeurs manquantes	% du total
Age_premiere_consommation	80	13.33%

2.3 Anomalie détectée sur la variable catégorielle « Genre »

L'inspection des modalités révèle une incohérence de saisie : certaines valeurs sont enregistrées en majuscules (« FEMME », « HOMME »).

3. Nettoyage des données

Le nettoyage a porté sur quatre axes : la suppression des doublons, la correction des incohérences de saisie, le traitement des valeurs manquantes et le traitement des valeurs aberrantes.

3.1 Suppression des doublons

Aucune ligne strictement dupliquée n'a été identifiée ni supprimée.

3.2 Correction des incohérences catégorielles

Les modalités de la variable « Genre » ont été harmonisées (normalisation de la casse) pour ne conserver que « Homme » et « Femme ».

3.3 Traitement des valeurs aberrantes (méthode IQR)

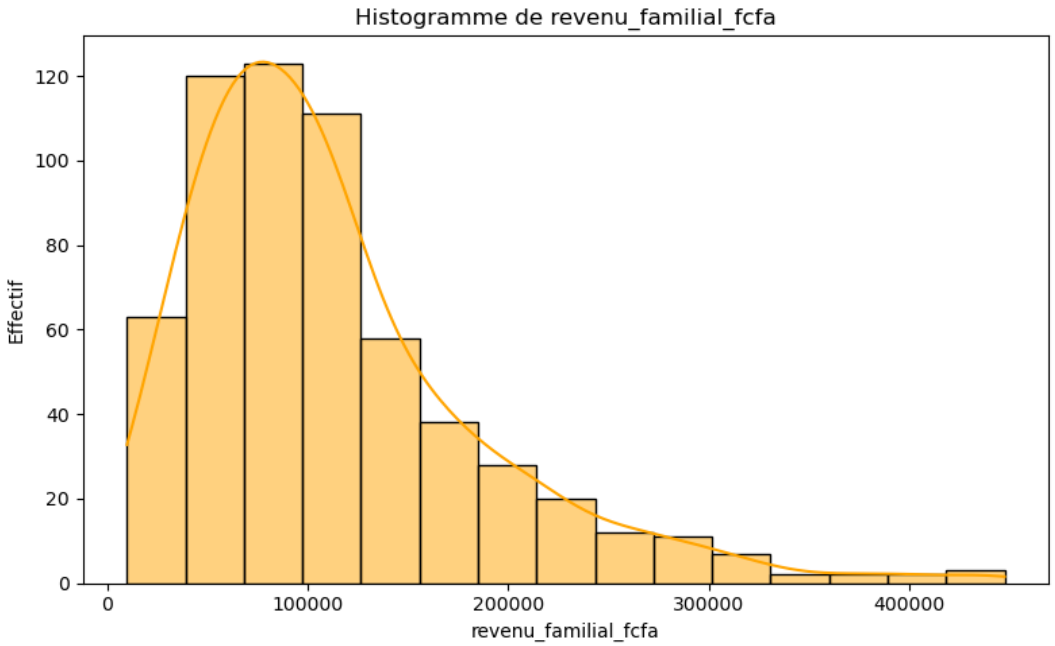
Sur la variable revenu familial FCFA, la méthode interquartile (IQR) a été utilisée : toute valeur en dehors de l'intervalle [-59622.0, 262774.0] a été ramenée à la borne la plus proche (winsorisation). 571 valeurs ont ainsi été corrigées.

3.4 Bilan du nettoyage

600 Lignes avant	**600** Lignes après	**0** Doublons retirés	**80** Valeurs manquantes restantes

4.Analyse univariée des variables quantitatives

Statistique	Valeur
Moyenne	112096.218333
Médiane	95636.500000
Écart-type	73369.295282
Minimum	9897.000000
Maximum	447668.000000
1er quartile (Q1)	61276.500000
3e quartile (Q3)	141875.500000
Asymétrie (skewness)	1.500
Aplatissement (kurtosis)	2.836



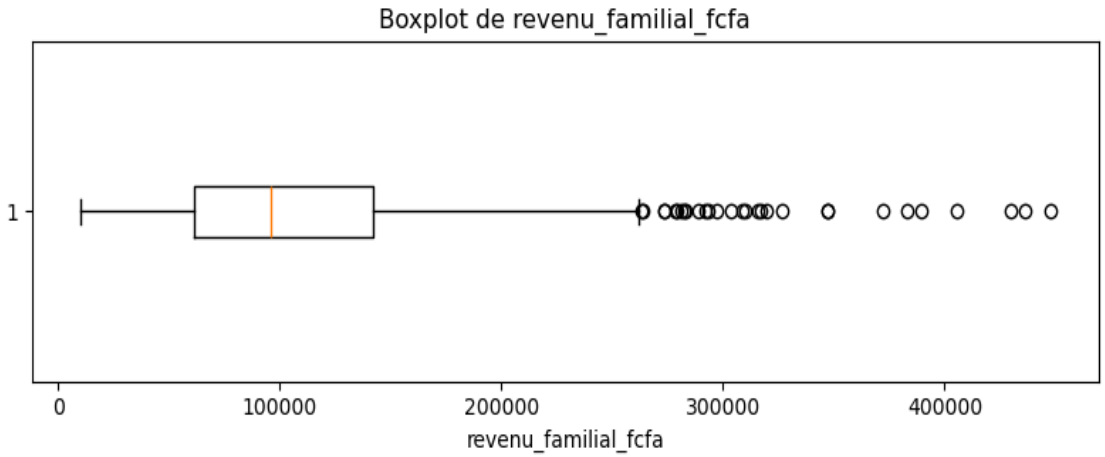
L'histogramme met en évidence la distribution du revenu familial des patients.
On constate une concentration des données à gauche (faibles et moyens revenus) et une longue queue étirée vers les valeurs élevées (asymétrie à droite ou skewness positive).

Interprétation

La majorité des ménages dispose de revenus modestes à modérés, tandis qu'une minorité de patients bénéficie de revenus nettement plus élevés (revenus atypiques ou « VIP »).

Lien avec la problématique

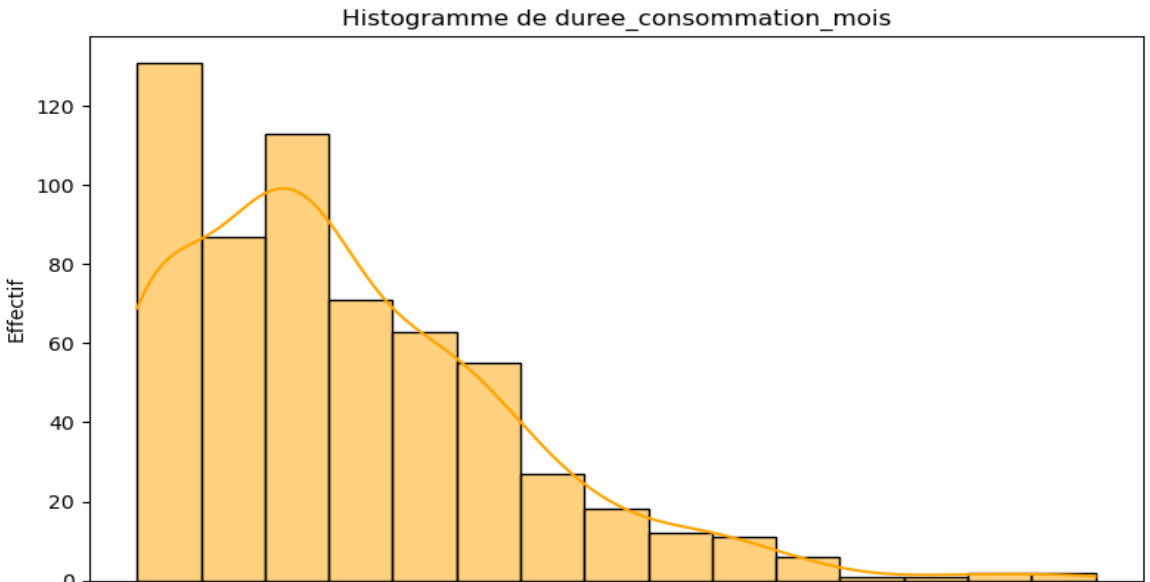
Ce déséquilibre économique direct ne suffit pas à expliquer à lui seul le score dépendance SDS des patients, mais il conditionne toute l'analyse statistique ultérieure



Le boîte à moustaches (boxplot) met en évidence la distribution du revenu familial des patients.

Cela s'explique par l'existence d'un sous-groupe restreint de patients disposant d'un revenu familial particulièrement élevé par rapport à l'ensemble de la population étudiée.

Statistique	Valeur
Moyenne	14.6290
Médiane	12.3500
Écart-type	12.0397
Minimum	0.0000
Maximum	68.2000
1er quartile (Q1)	5.5000
3e quartile (Q3)	21.4250
Asymétrie (skewness)	1.109
Aplatissement (kurtosis)	1.583



L'histogramme présente la distribution de la durée de consommation de drogue (en mois) chez les patients.

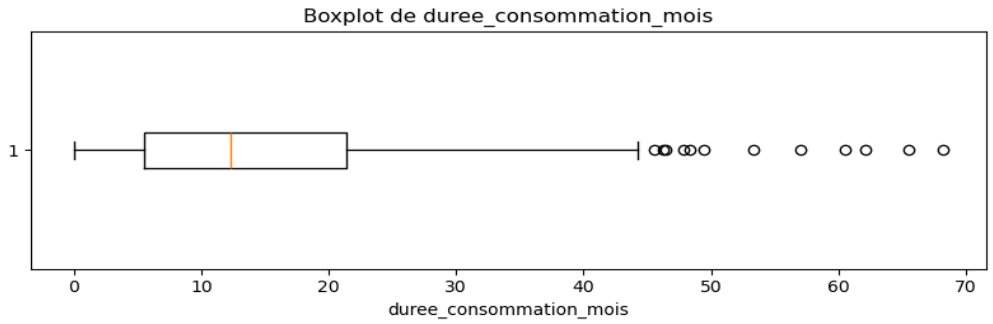
On observe une forte concentration des données à gauche (durées de consommation courtes à modérées) et une longue queue étirée vers la droite (*skewness* positive / asymétrie à droite).

Interprétation

La distribution présente un premier pic entre 0 et 5 mois (plus de 130 patients) et un second pic notable entre 9 et 14 mois (plus de 110 patients).

Lien avec la problématique

Cela suggère que la durée de consommation de drogue (en mois) constitue une variable structurante, potentiellement discriminante dans l'étude du score dépendance SDS des patients. Toutefois, une analyse comparative approfondie reste nécessaire afin de confirmer son influence et son rôle explicatif.



Le boxplot met en évidence :

- ❖ Une dispersion importante,
- ❖ De nombreuses valeurs élevées.

Interprétation

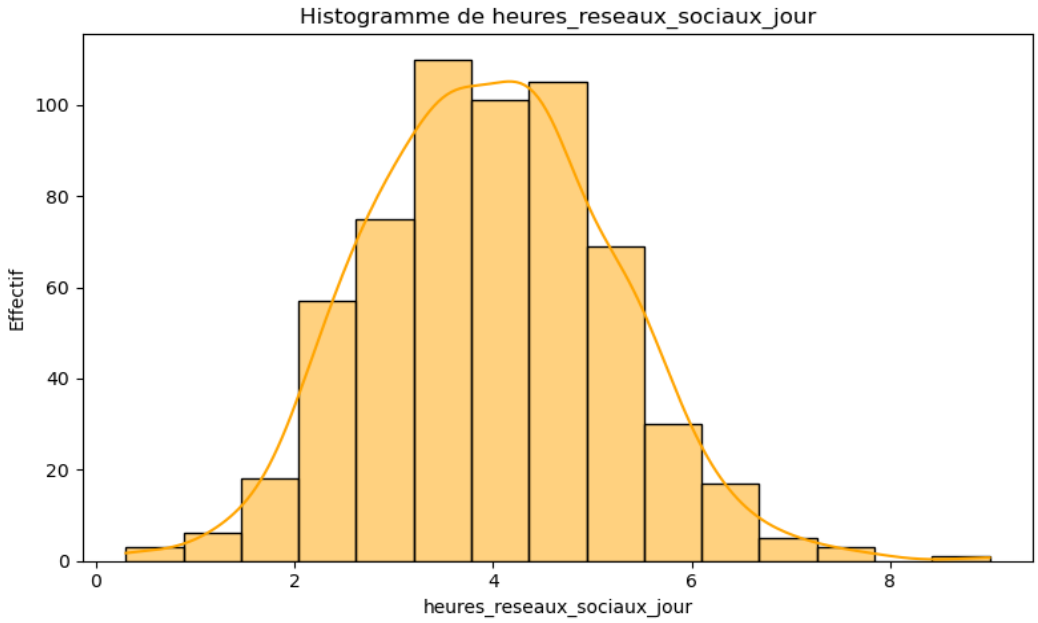
Ces durées élevées correspondent à des profils de consommateurs chroniques à très long terme. D'un point de vue médical, ces valeurs atypiques sont parfaitement plausibles et doivent être conservées dans la base de données (pas de rejet comme erreur de saisie).

Lien avec la problématique

La durée de consommation est une variable explicative clé pour le score de qualité de vie.
En raison de l'étalement vers les valeurs élevées, il conviendra d'utiliser la médiane plutôt que la moyenne pour résumer cette variable, et de privilégier des tests non paramétriques (ou une transformation logarithmique) pour étudier sa relation avec du `score` dépendance SDS.

.

Statistique	Valeur
Moyenne	3.9696
Médiane	4.0000
Écart-type	1.2187
Minimum	0.3000
Maximum	9.0000
1er quartile (Q1)	3.1000
3e quartile (Q3)	4.8000
Asymétrie (skewness)	1.500
Aplatissement (kurtosis)	2.836



L'histogramme met en évidence le nombre d'heures passées sur les réseaux sociaux par jour chez les patients.

La distribution est globalement symétrique et unimodale, centrée autour de 4 heures par jour, avec des queues de distribution équilibrées à gauche et à droite. On note une très légère traînée vers la droite (légère asymétrie à droite), mais la forme générale se rapproche fortement d'une loi normale.

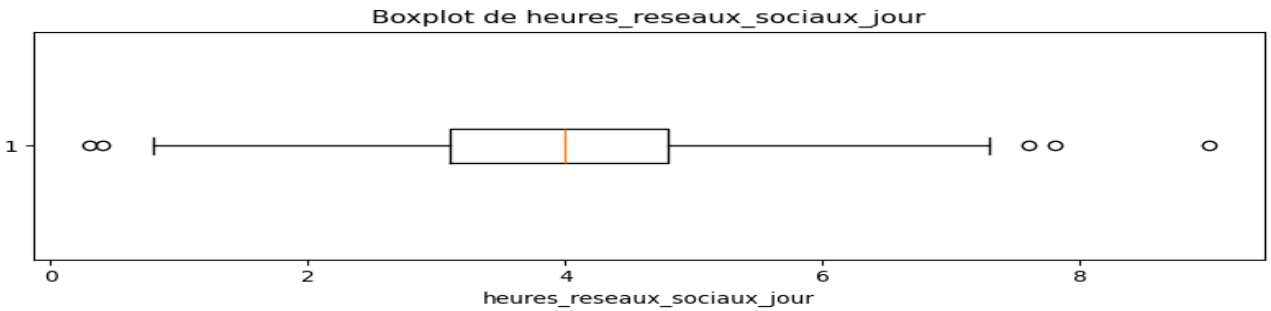
Interprétation

La majorité des patients à un usage quotidien des réseaux sociaux modéré à moyen (entre 3 et 5 heures par jour). Les comportements extrêmes (moins de 1 heure ou plus de 7 heures par jour) restent rares, ne montrant pas de signal fort de valeurs aberrantes problématiques.

Lien avec la problématique

Indicateurs statistiques : Du fait de cette quasi-symétrie, la moyenne et la médiane seront très proches et constitueront toutes deux de bons indicateurs de tendance centrale (avec l'écart-type comme mesure de dispersion appropriée).

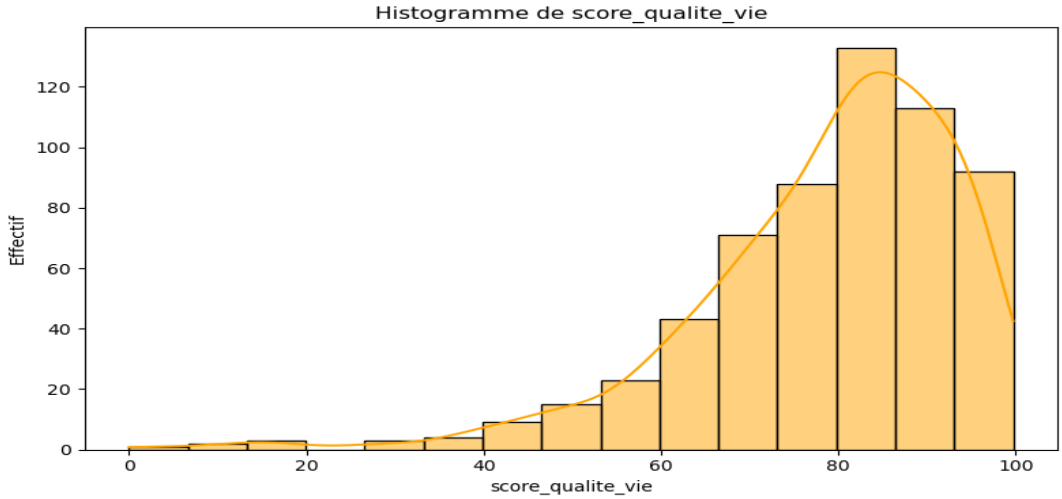
Modélisation : Contrairement au revenu ou à la durée de consommation de drogue, cette variable ne nécessite pas de transformation logarithmique préalable et peut être directement intégrée dans des modèles de régression paramétriques pour expliquer le score_dependance_SDS.



Le boxplot met en évidence 5 valeurs atypiques au total : 2 valeurs basses (en dessous de 1 heure) et 3 valeurs hautes (supérieures à 7,5 heures, dont une valeur extrême à plus de 9 heures).

La majorité des patients passent entre 3 et 5 heures par jour sur les réseaux sociaux. Un sous-groupe très réduit se distingue soit par un usage particulièrement faible (moins de 30 minutes), soit par un usage très intensif (dépassant 7,5 à 9 heures quotidiennes).

Statistique	Valeur
Moyenne	78.69
Médiane	81.85
Écart-type	15.09
Minimum	0.00
Maximum	99.70
1er quartile (Q1)	71.20
3e quartile (Q3)	89.60
Asymétrie (skewness)	-1.51
Aplatissement (kurtosis)	3.60

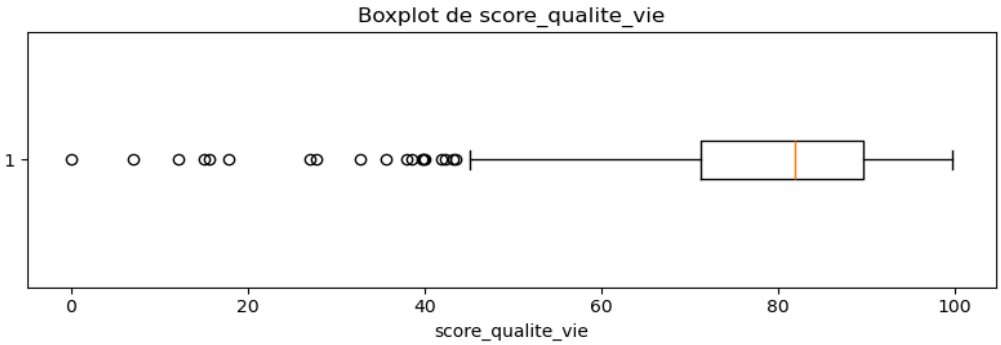


L'histogramme montre une forte concentration des données à droite et une longue queue étirée vers les faibles scores (asymétrie à gauche ou *skewness* négatif).

Le coefficient d'aplatissement (kurtosis) positif indique une distribution leptokurtique, caractérisée par un pic plus élevé et pointu au niveau des valeurs centrales/modales.
Interprétation

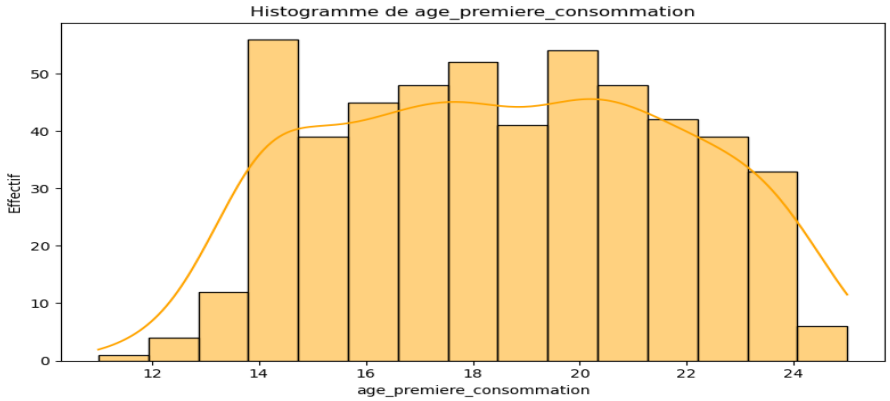
La majorité des patients présentent un score de qualité de vie très satisfaisant, la classe modale se situant principalement entre 80 et 87.

Lien avec la problématique
Le score de qualité de vie peut être un facteur explicatif potentiel du score de dépendance.



Le boxplot met en évidence de nombreuses valeurs atypiques (ou extrêmes) situées en dessous du premier quartile. Cela indique qu'un sous-groupe minoritaire de patients souffre d'une qualité de vie nettement plus faible que l'ensemble du groupe.

Statistique	Valeur
Moyenne	18.6269
Médiane	19.0000
Écart-type	3.2794
Minimum	11.0000
Maximum	25.0000
1er quartile (Q1)	16.0000
3e quartile (Q3)	21.0000
Asymétrie (skewness)	0.008
Aplatissement (kurtosis)	-1.048



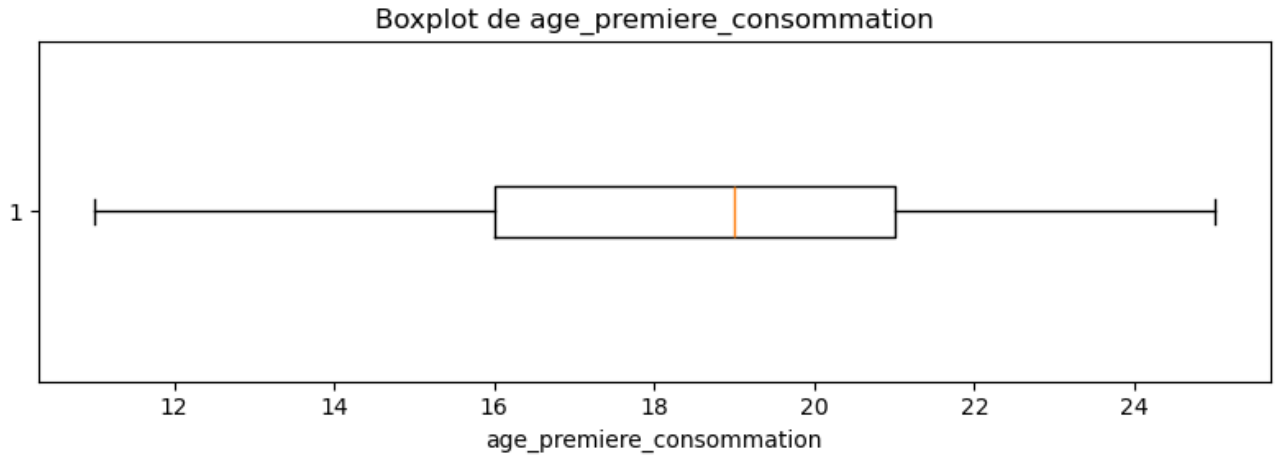
L'histogramme présente une distribution étalée (platikurtique) avec plusieurs pics secondaires (notamment vers 14, 18 et 20 ans).

Interprétation

L'initiation à la consommation de drogue ne se produit pas à un âge unique ou dominant, mais s'étale de manière continue tout au long de l'adolescence et du début de la vie adulte (14–21 ans).

Lien avec la problématique du score de dépendance (SDS)

Une première consommation précoce (notamment le pic observé dès 14 ans) est un facteur de risque majeur fréquemment associé à des scores de dépendance ultérieurs plus élevés. Il sera pertinent de croiser cette variable avec le score SDS via un test de corrélation (ex. Spearman ou Pearson)



L'âge médian de première consommation de drogue est de 19 ans. L'écart interquartile montre que 50 % des patients ont commencé à consommer entre 16 ans (Q_1) et 21 ans (Q_3).

Bien que la moitié centrale de la population s'initie à la consommation entre 16 et 21 ans, la présence d'une moustache inférieure allongée souligne qu'un sous-groupe significatif commence à consommer plus précocement (dès 11 ans), nécessitant une attention particulière en matière de prévention ciblant l'adolescence.

4. Analyse univariée Variables catégorielles

L'analyse des variables catégorielles met en évidence :

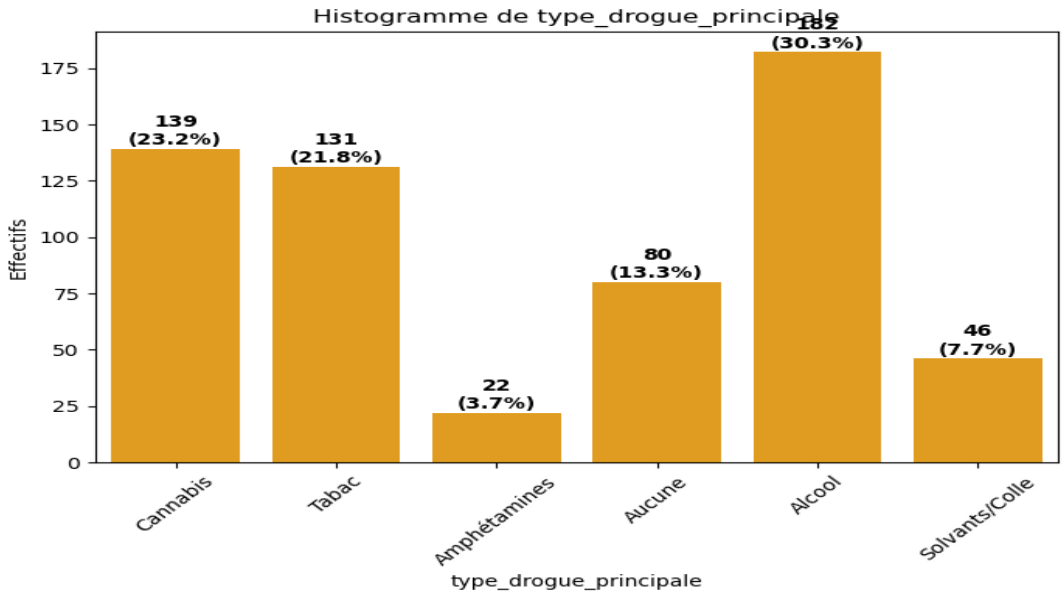
- ❖ Des déséquilibres de modalités pour certaines variables,
- ❖ Des distributions très hétérogènes selon les variables.

Ces observations impliquent :

- ❖ Une réflexion sur l'encodage,
- ❖ Une attention particulière aux biais,
- ❖ Une prudence dans l'interprétation des associations.

À ce stade, aucune relation causale n'est avancée.

4.1 Type de drogue



Ce graphique met en évidence que l'alcool est le type de drogue le plus représenté, avec un effectif de 182 patients (30,3 %). Il est suivi par le cannabis (139 patients, soit 23,2 %) et le tabac (131 patients, soit 21,8 %). Enfin, les autres types de drogues sont nettement moins fréquents, notamment les solvants/colle (46 patients, soit 7,7 %) et les amphétamines (22 patients, soit 3,7 %).

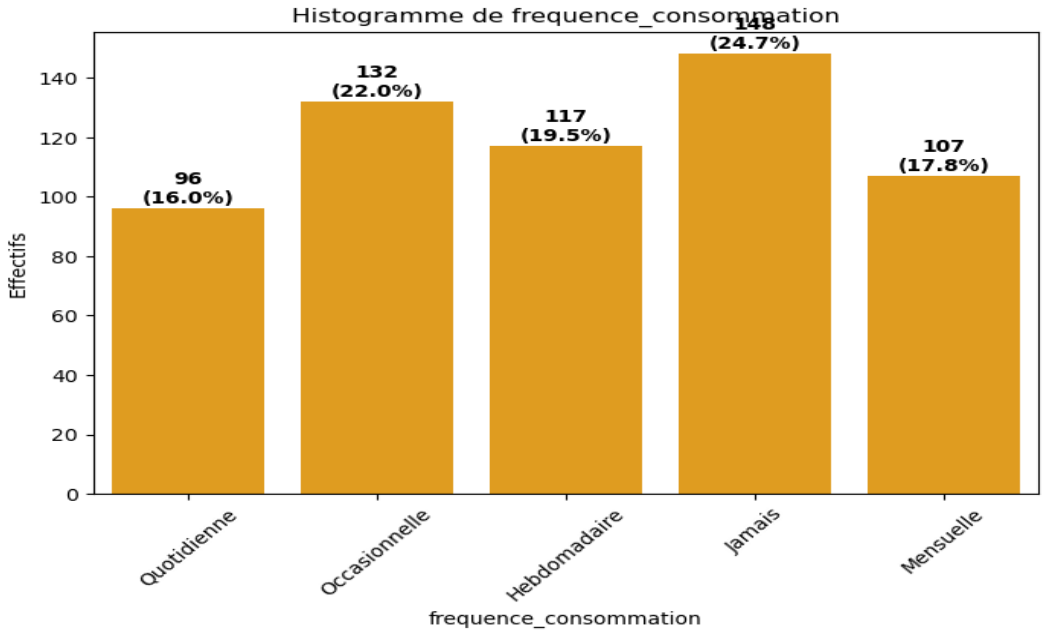
Interprétation

Cette répartition montre que l'alcool constitue la modalité dominante au sein de l'échantillon, formant avec le cannabis et le tabac le trio de substances largement majoritaire (plus de 75 % des cas).

Lien avec la problématique le score de dépendance

Le type de drogue principale peut être étudié comme facteur associé au score de dépendance. Toutefois, la faible représentation de certaines modalités (amphétamines et solvants/colle) impose une prudence méthodologique dans l'analyse statistique

4.2 Fréquence consommation de drogue



Ce graphique met en evidence la frequence de consommation de drogue chez les patients.

Les patients n'ayant « Jamais » consommé représentent la catégorie la plus importante avec 148 patients (24,7 %). Ils sont suivis par ceux ayant une consommation « Occasionnelle » (132 patients, soit 22,0 %), « Hebdomadaire » (117 patients, soit 19,5 %) et « Mensuelle » (107 patients, soit 17,8 %). Enfin, la fréquence de consommation « Quotidienne » concerne 96 patients (soit 16,0 %).

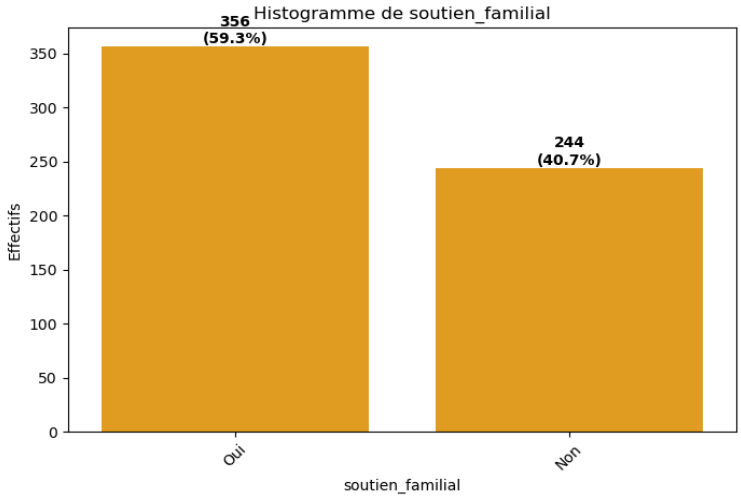
Interpretation

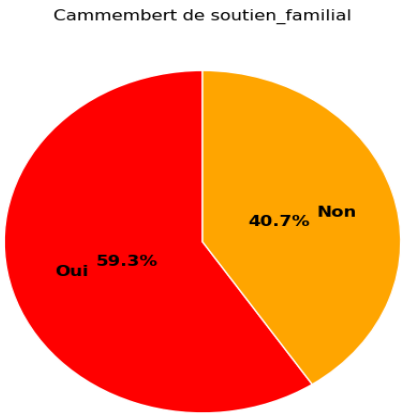
Les effectifs sont répartis de manière relativement équilibrée entre les différentes fréquences, même si la modalité « Jamais » prédomine légèrement. On observe toutefois que plus des trois quarts de l'échantillon (75,3 %) déclarent une consommation active de drogues, à des rythmes variables allant d'occasionnel à quotidien.

Lien avec la problématique le score de dépendance

La fréquence de consommation constitue une variable explicative clé pouvant être liée au score de dépendance. Une analyse bivariée (par exemple un test d'ANOVA ou de Kruskal-Wallis si le score est continu, ou un test du Chi-deux s'il est catégorisé) permettra de vérifier l'existence d'une association statistiquement significative entre la fréquence de consommation et le niveau de dépendance.

4.3 Soutien familial





Cet histogramme indique que la majorité des patients bénéficie d'un soutien familial, représentée par 356 patients (59,3 %). En comparaison, la catégorie ne bénéficiant pas de soutien familial rassemble 244 patients (40,7 %).

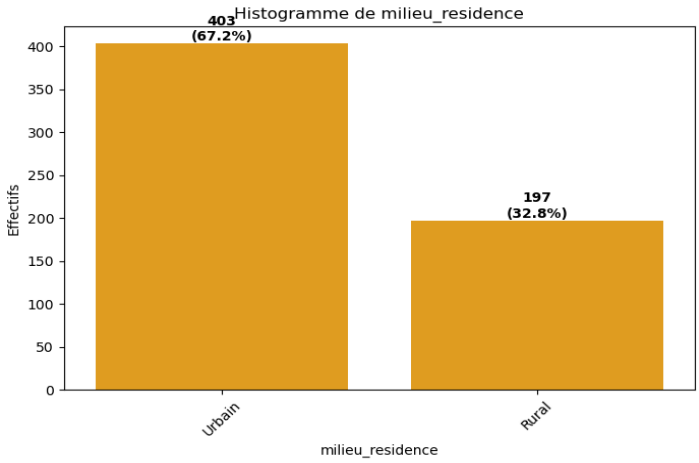
Interprétation

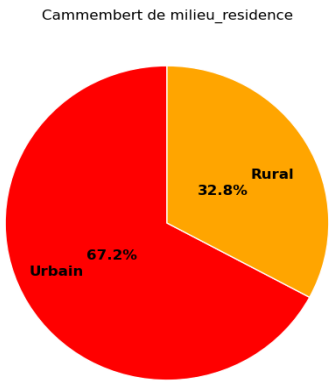
Cette distribution montre une prédominance des patients bénéficiant d'un accompagnement familial au sein de l'échantillon (près de 6 patients sur 10). Toutefois, la proportion de patients dépourvus de soutien reste notable et concerne plus de 40 % de la population étudiée.

Lien avec la problématique le score de dépendance

La variable soutien familial peut être analysée comme une variable explicative ou un facteur protecteur influent sur le score de dépendance. Une analyse bivariée permettra d'évaluer s'il existe une différence statistiquement significative du score de dépendance selon la présence ou l'absence de soutien

4.4 Milieu résidence





L’analyse du graphique indique que la majorité des patients réside en milieu urbain, soit 403 patients (67,2 %). Les patients vivant en milieu rural représentent quant à eux 197 patients (32,8 %), soit environ un tiers de la population étudiée.

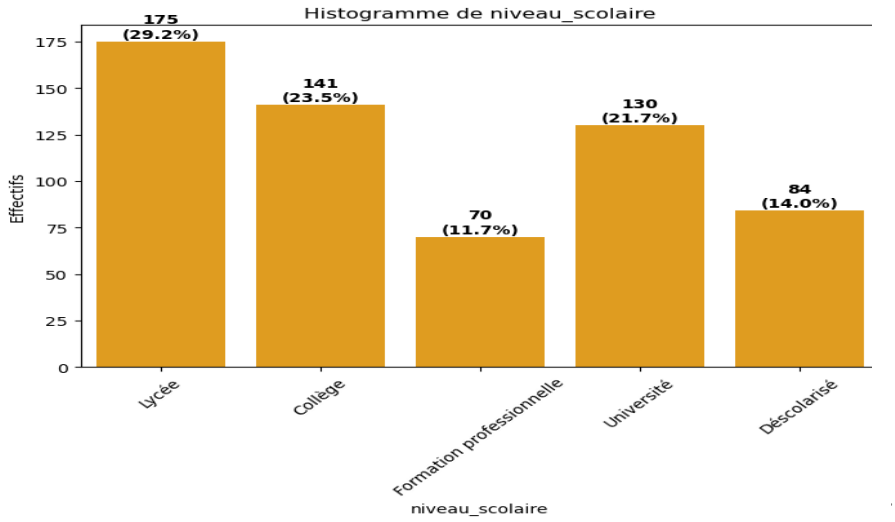
Interprétation

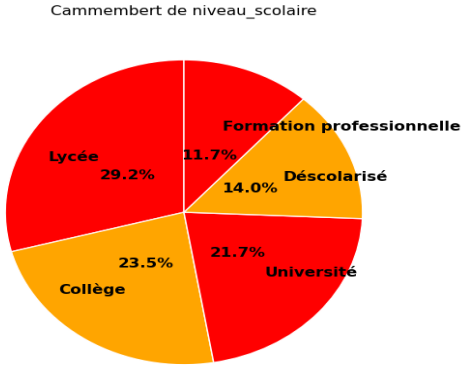
Cette distribution montre une prédominance des résidents du milieu urbain au sein de l'échantillon (environ 2 patients sur 3). Cet écart peut s'expliquer par une plus grande proximité géographique des structures de soin en zone urbaine ou par une exposition différente aux facteurs de risque. Lien avec la problématique le score de dépendance

Lien avec la problématique le score de dépendance

Le lieu de résidence constitue un facteur contextuel potentiel (accès aux soins, mode de vie, environnement socio-économique) pouvant être lié au score de dépendance. Mais aucune conclusion ne peut être tirée à ce stade sans analyse bivariée.

4.5 Niveau scolaire





Le niveau Lycée constitue la modalité la plus représentée au sein de la population étudiée, comptabilisant 175 patients (29,2 %). Il est suivi par le Collège avec 141 patients (23,5 %) et l'Université avec 130 patients (21,7 %). Enfin, les catégories les moins représentées sont les patients Déscolarisés (84 patients, soit 14,0 %) et ceux issus de la Formation professionnelle (70 patients, soit 11,7 %).

Interprétation

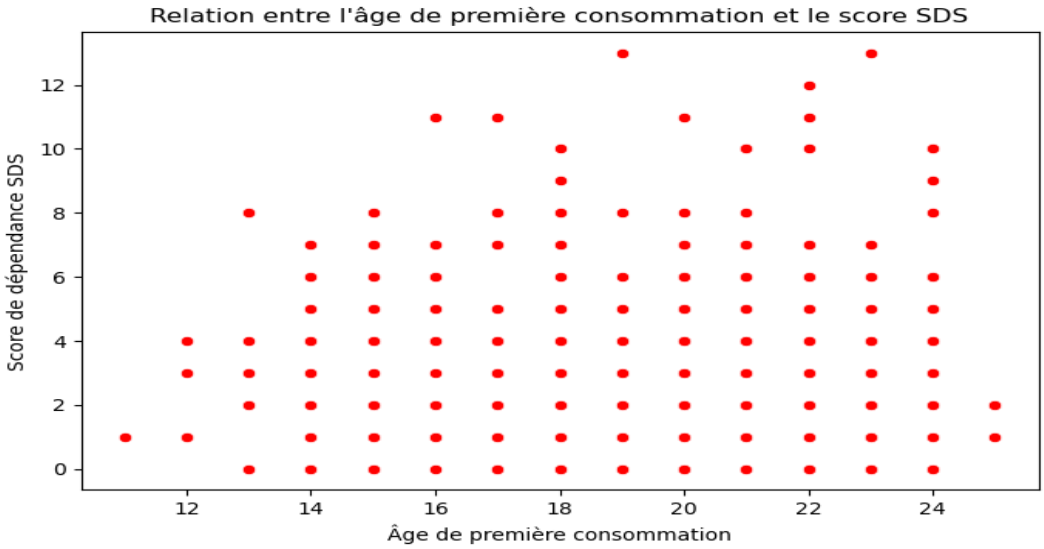
La distribution met en avant une concentration majoritaire des patients dans le système d'enseignement général (Lycée, Collège, Université), regroupant à eux seuls 74,4 % de l'échantillon. Le niveau Lycée émerge comme la classe modale, représentant près d'un tiers des sujets. Bien que la répartition ne présente pas d'asymétrie extrême, les filières professionnelles et les situations de déscolarisation restent nettement minoritaires, constituant chacune environ un dixième de la cohorte.

Lien avec la problématique le score de dépendance

Le niveau scolaire est une variable susceptible d'influencer le score de dépendance, car celui-ci peut varier selon le parcours éducatif des jeunes. Une analyse comparative des scores de dépendance entre les différents niveaux scolaires est toutefois nécessaire pour confirmer l'existence de cette relation.

7. Analyse bivariée Variables numériques vs variable numérique

7.1 Age de première consommations vs le score de dépendance SDS



Le nuage de points montre une grande dispersion des observations. Les points sont répartis sur l'ensemble du graphique sans former une tendance linéaire claire.

On observe toutefois une légère tendance :

- Les individus ayant commencé la consommation à un âge plus élevé (environ 18–24 ans) présentent parfois des scores SDS plus élevés ;
- Cependant, les scores restent très variables pour un même âge.

Interprétation

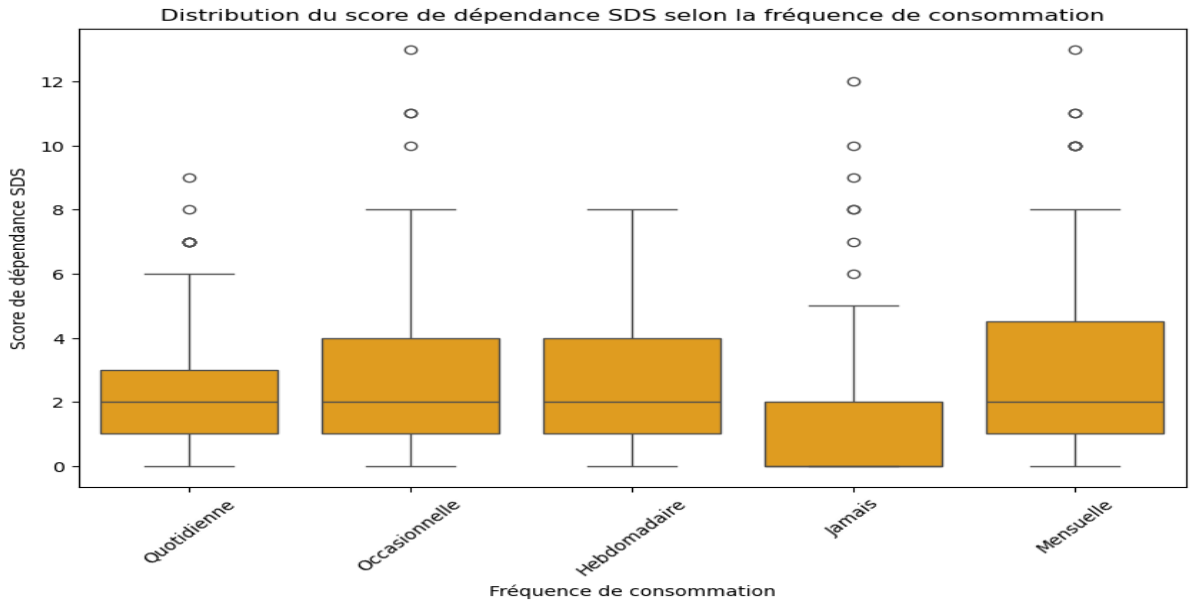
Le nuage de points met en évidence une forte dispersion des scores de dépendance SDS selon l'âge de première consommation. Aucune tendance linéaire ou monotone claire n'est observée. Cette observation est confirmée par le test de corrélation de Spearman ($\rho = 0{,}059$; $p = 0{,}180$), indiquant une corrélation positive très faible mais non significative. Ainsi, dans cet échantillon, l'âge de début de consommation n'explique pas fortement les différences de score de dépendance.

Statistique	Valeur
Coefficient de corrélation de Spearman	0,059
P-value	0,180
Interprétation	Pas de corrélation monotone statistiquement significative entre l'âge de première consommation et le score de dépendance SDS dans votre échantillon.

8. Analyse bivariée Variable catégorielle vs variable numérique

La relation entre une variable qualitative et une variable quantitative est étudiée via les statistiques par groupe (moyenne, médiane, écart-type), une visualisation en boîtes à moustaches, et un test de Krystal walis.

8.1 Score de dépendance vs fréquence de consommation



Le boxplot montre que le score de dépendance SDS varie selon la fréquence de consommation.

Les niveaux occasionnelle, hebdomadaire et mensuelle présentent des médianes proches, autour de 2, avec une dispersion relativement importante.

La catégorie « Jamais » présente globalement les scores SDS les plus faibles, avec une médiane proche de 0, ce qui est cohérent avec une faible dépendance.

La catégorie quotidienne présente une dispersion plus modérée et une médiane autour de 2.

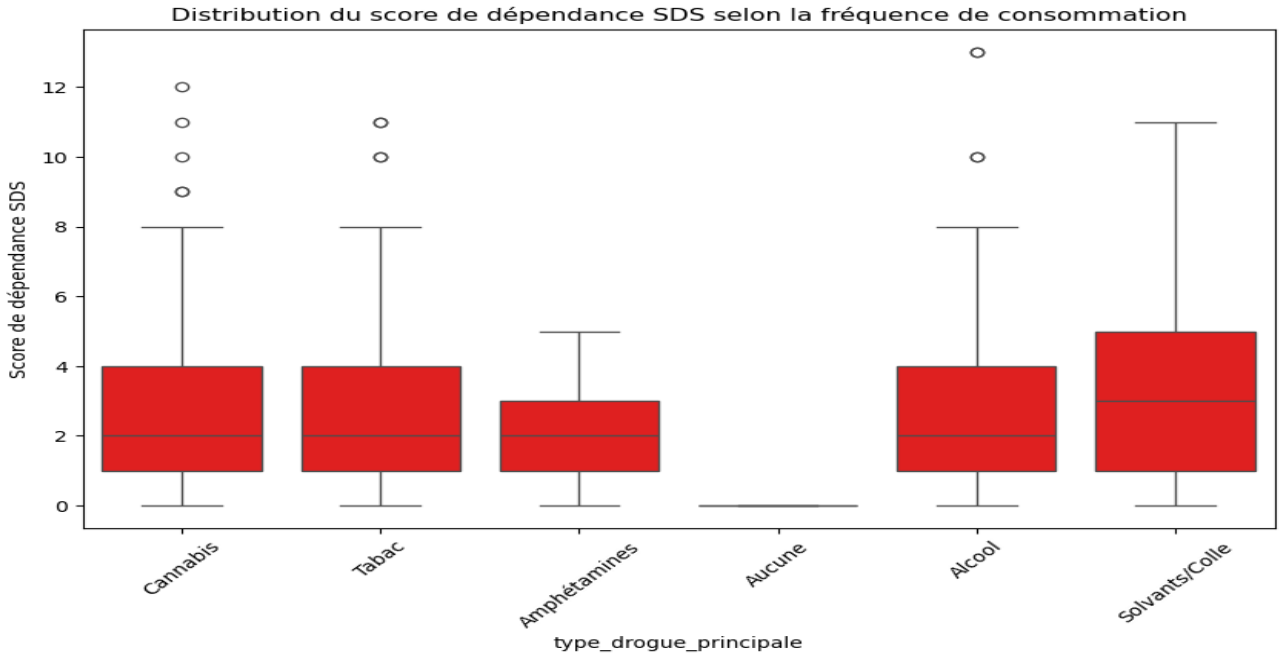
On observe également une dispersion importante et plusieurs valeurs aberrantes, notamment dans les catégories « occasionnelle », « jamais » et « mensuelle », avec des scores pouvant atteindre 10–13.

Interprétation

La fréquence de consommation est significativement associée au score de dépendance SDS, comme le confirme le test de Kruskal-Wallis ($p < 0,05$). Ainsi, la fréquence de consommation constitue un facteur explicatif potentiel du niveau de dépendance, les profils de consommation étant associés à des niveaux de score SDS différents.

Statistique du test de Kruskal-Wallis	Valeur
H	102,25
P-value	$3,26 \times 10^{-21}$,
Conclusion (seuil 5%)	Le score de dépendance varie selon la fréquence de consommation.

8.2 Type de drogue vs score de dépendance



Le boxplot montre que le score de dépendance SDS varie selon le type de drogue. Les catégories Cannabis, Tabac et Alcool présentent une médiane autour de 2, tandis que la catégorie Solvants/colle présente une médiane plus élevée, autour de 3, avec une dispersion également plus importante. La catégorie Amphétamines présente des scores globalement plus faibles et moins dispersés, alors que la modalité Aucune se caractérise par un score SDS quasiment nul.

On observe également plusieurs valeurs atypiques élevées pour le cannabis, le tabac et l'alcool, atteignant environ 10 à 13, ce qui indique que certains individus présentent une dépendance particulièrement élevée malgré leur appartenance à ces catégories.

Ces conditions violent les hypothèses de normalité et d'homogénéité des variances requises par une ANOVA classique. Le test de Kruskal-Wallis, non paramétrique, est donc plus adapté : il compare les rangs plutôt que les moyennes, ce qui le rend robuste aux valeurs extrêmes et aux distributions non normales.

Interprétation

La type de consommation est significativement associée au score de dépendance SDS, comme le confirme le test de Kruskal-Wallis ($p < 0,05$). Ainsi, le type de drogue constitue un facteur explicatif potentiel du niveau de dépendance, le type de drogue étant associés à des niveaux de score SDS différents.

Statistique du test de Kruskal-Wallis	Valeur
H	183.16
P-value	$1.13\times 10^{-}37$
Conclusion (seuil 5%)	Le score de dépendance varie selon le type_drogue_principale.

9. Apports et limites de l'analyse exploratoire

Apports :
- Compréhension fine des distributions,
- Identification des variables structurantes,
- Choix justifié des méthodes statistiques.

Limites :
- Absence de causalité,
- Déséquilibre de classes,
- Dépendance à la qualité du préprocessing.

L'EDA éclaire, mais **ne tranche pas**.

Conclusion

Ce projet montre que l'analyse exploratoire est une **étape fondamentale** en science des données.
Elle permet :
- De comprendre avant de modéliser,
- D'interpréter avant de conclure,
- et d'éviter des erreurs méthodologiques majeures.

La suite naturelle de ce travail consistera à :
- Traiter les valeurs manquantes,
- Corriger les déséquilibres,
- et construire des modèles explicatifs ou prédictifs sur des bases solides.